É possível prever a qualidade de um vinho pelos seus dados?

Análise exploratória e modelos de classificação a partir de 1.143 amostras.

A pergunta de negócio: transformar medições físico-químicas em apoio à decisão.

Primeiro, o desafio é separar sinal de ruído

1.143 amostras

A base contém 1.143 vinhos e 11 características físico-químicas, além da nota e do identificador.

Dados completos

Não foram encontrados valores ausentes nem linhas duplicadas na verificação inicial.

Alvo binário

Alta qualidade: nota ≥ 7.
Baixa/média: nota < 7.

A escolha do corte simplifica a decisão, mas também perde nuances entre as notas.

A classificação “alta qualidade” representa apenas 159 amostras (13,9%); 984 amostras (86,1%) estão na outra classe.

Álcool, acidez volátil e sulfatos se destacam

Teor alcoólico

Maior associação linear positiva com a classe de alta qualidade (r ≈ +0,40).

Acidez volátil

Associação negativa (r ≈ −0,30): valores mais altos tendem a aparecer menos na classe alta.

Sulfatos e ácido cítrico

Associações positivas moderadas (r ≈ +0,21 e +0,25).

Correlação não prova causa. São pistas para investigar com especialistas e validar em novos dados.

Na Random Forest, as maiores importâncias foram álcool (0,215), ácido cítrico (0,147) e sulfatos (0,146).

A Random Forest teve o melhor desempenho geral

Métrica	Regressão Logística	Random Forest
Acurácia	79,9%	91,3%
Precisão (classe alta)	37,9%	73,1%
Recall (classe alta)	68,8%	59,4%
F1-score (classe alta)	0,49	0,66
ROC-AUC	0,85	0,91

Leitura executiva: a Random Forest erra menos no conjunto total e identifica melhor o padrão geral.

Mas ainda deixou passar 13 dos 32 vinhos de alta qualidade no teste.

O melhor modelo depende do custo do erro

Se o objetivo é evitar falsos alarmes

A Random Forest foi mais precisa: quando prevê alta qualidade, acerta com mais frequência.

Se o objetivo é não perder bons vinhos

A Regressão Logística capturou mais casos de alta qualidade (recall de 68,8%), mas gerou mais falsos positivos.

Próximo passo: escolher o limiar de decisão conforme o objetivo do negócio e testar o modelo em dados de outras safras, regiões e produtores.

O modelo deve apoiar a avaliação técnica — não substituir enólogos nem provar relações de causa e efeito.

CONCLUSÃO

Dados não substituem a experiência.

Eles ajudam a direcioná-la.

A análise encontrou sinais úteis e a Random Forest alcançou ROC-AUC de 0,91 no teste. O próximo passo é validar em dados reais de produção e ajustar a decisão ao custo de cada erro.

Obrigado.

Repositório com o código: https://github.com/NathanSGomes/TechChallenge_Fase2_FIAP

Vídeo de explicação: https://www.youtube.com/watch?v=ZRznTzCW7YU